

Clase 07 - Fundamentos de datos y servicios de Azure para Datos

Autor: Christian Salguero Varas

Fecha: 23/09/2026

Ejercicio 1 — Clasifica las fuentes

Clasifica cada fuente como estructurada, semiestructurada o no estructurada y justifica tu respuesta:

1. Exportación diaria del ERP de compras en CSV.

Estructurada.

2. Lecturas de temperatura de las cámaras frigoríficas enviadas cada 30 segundos en JSON.

Semiestructurada.

3. Grabaciones MP3 del servicio de atención al cliente.

No estructurada.

4. Tabla Empleados de la base de datos de RR. HH.

Estructurada.

5. Logs de acceso de la tienda online.

Semiestructurada.

6. Fotografías de los lineales tomadas por los reponedores.

No estructurada.

Ejercicio 2 - Elige el formato

Para cada escenario de Grupo Alimenta, elige el formato más adecuado y justifica la decisión:

1. Un proveedor pequeño nos envía cada semana su tarifa de precios y solo sabe trabajar con Excel.

CSV, desde Excel puedes exportar directamente a CSV y si no son una cantidad masiva de datos se puede trabajar con ellos y convertirlos a otro formato mejor diseñado para el objetivo del proyecto.

2. Almacenar 5 años de líneas de ticket para que los analistas estudien la estacionalidad de ventas por familia de producto.

El mejor formato es Parquet. Parquet ofrece almacenamiento columnar, lo que nos permite leer directamente las columnas relevantes sin escanear todo el dataset. Además, incluye comprensión y metadatos.

3. Tabla de socios de fidelización que se actualiza a diario y sobre la que el delegado de protección de datos exige poder ver cómo estaba hace un mes.

El formato recomendado es Delta Lake ya que aporta transacciones ACID (para poder realizar actualizaciones y borrados diarios de forma segura) y, control de versiones a través de su transaction log. Esto permite consultar el estado exacto de la tabla en cualquier punto pasado.

4. Flujo continuo de lecturas de temperatura de las cámaras frigoríficas.

El formato recomendado es Avro para la transmisión e ingesta en streaming y Delta/Parquet para el almacenamiento histórico. Avro es el estándar debido a su baja latencia y su compactación. Una vez ingerido sería mejor hacer uso de Delta Lake / Parquet.

5. Recepción de pedidos de compra con un gran proveedor que usa EDI.

El formato recomendado es EDIFACT o X12 que es el estándar internacional para el intercambio de documentos comerciales en EDI.

Ejercicio 3 - OLTP u OLAP

Indica si cada necesidad corresponde a un sistema transaccional o analítico:

1. Aplicar un cupón de descuento en la caja.

OLTP. Requiere baja latencia, procesamiento en tiempo real y una operación rápida.

2. Calcular la evolución de las ventas de productos ecológicos en los últimos 3 años.

OLAP. Requiere de agregaciones complejas sobre un gran volumen de datos históricos.

3. Consultar si queda aceite de oliva en la tienda de Valencia ahora mismo.

OLTP. Una consulta puntual de inventario sobre el estado actual en tiempo real.

4. Detectar qué tiendas tienen más roturas de stock los lunes.

OLAP. Requiere analizar el comportamiento histórico de múltiples tiendas agrupando la información por día de la semana para identificar patrones.

5. Actualizar la dirección de entrega de un pedido online en curso.

OLTP. Se trata de una operación de modificación (UPDATE) puntual en la base de datos, donde importa la consistencia de la transacción (propiedades ACID).

Ejercicio 4 — ¿Qué rol es responsable?

1. El informe de ventas lleva dos días sin actualizarse porque ha fallado la carga nocturna.

Ingeniero de Datos (Data Engineer).

2. Hay que restaurar la base de datos de la tienda online tras un borrado accidental.

Administrador de Bases de Datos (DBA) / Ingeniero de Datos. Depende de quién tenga los permisos para restaurar las copias de seguridad.

3. Dirección quiere un nuevo gráfico de margen por familia de producto en el cuadro de mando.

Analista de Datos (Data Analyst).

4. Atención al cliente quiere un asistente que responda "¿cuándo llega mi pedido?".

Ingeniero de IA.

5. Hay que enmascarar los teléfonos de los socios antes de que lleguen a la capa analítica.

Ingeniero de Datos (Data Engineer).

6. Marketing quiere saber qué socios tienen mayor probabilidad de dejar de comprar en los próximos 3 meses.

Científico de Datos (Data Scientist).

7. Se debe decidir si la plataforma se construye en Fabric, en Databricks o combinando ambos.

Arquitecto de Datos (Data Architect).

8. Dos departamentos presentan en el comité cifras distintas de "venta neta" para el mismo mes.


Analytics Engineer.

Ejercicio 5 : Investiga y arma un diagrama de arquitectura de capas (como el de la sección 8) con cada una de estas tecnologías:


- Databricks (no Azure Databricks)




- Microsoft Fabric. Es decir todo enteramente dentro de Fabric



- AWS



- GCP




- Herramientas Open Source (el mas importante de todos)



- ¿Y que pasa con Snowflake , dbt y DuckDB? ¿En que casos se utilizan? ¿En que capas se pueden incluir o con cuales otras tecnologías se puede combinar? Crear al menos 3 diagramas para este caso. Este es el estándar actual de la industria. Extraes con una herramienta, guardas en Snowflake y transformas con dbt.



Ideas para proyectos más ligeros o económicos donde no quieres pagar un Data Warehouse enorme. dbt se conecta a DuckDB para orquestar la lógica SQL de transformación.



Se usa cuando tienes un volumen masivo de datos generados en local (por ejemplo, logs de servidores) y necesitas filtrarlos antes de subirlos a la nube.



Sección 10: Caso práctico — Plataforma de datos de Grupo Alimentaria

Contexto

Grupo Alimentaria quiere tres cosas:

1. Un **cuadro de mando de ventas, margen y roturas de stock** por tienda y familia de producto.

- 2. Un **modelo de previsión de demanda** de productos frescos para reducir la merma.
- 3. Un **asistente para atención al cliente** que responda sobre el estado de los pedidos online.

Fuentes disponibles:

Fuente	Tecnología	Tipo de dato	Frecuencia
TPV de tiendas y ERP de compras	Azure SQL Database	Estructurado	Cambios continuos
App de fidelización	Azure Cosmos DB (JSON)	Semiestructurado	Eventos continuos
Sensores de cámaras frigoríficas	Dispositivos IoT	Semiestructurado (streaming)	Cada 30 segundos
Tarifas de proveedores	CSV por SFTP	Estructurado	Semanal
Facturas de proveedores	PDF escaneados	No estructurado	Por factura
Meteorología y festivos	API pública	Semiestructurado	Diario

Tareas

1. Clasificación. Clasifica cada fuente (estructurada, semiestructurada, no estructurada) e indica si es OLTP, fichero o stream.

Fuente	Tipo de dato	OLTP, fichero o stream
TPV / ERP (Azure SQL)	Estructurado	OLTP
App Fidelización (Cosmos DB)	Semiestructurado	OLTP
Sensores Frigoríficos (IoT)	Semiestructurado	Stream
Tarifas Proveedores (SFTP)	Estructurado	Fichero
Facturas (PDF)	No estructurado	Fichero
Meteorología y Festivos (API)	Semiestructurado	Stream / Batch (API)

2. Arquitectura. Dibuja una arquitectura con capas Bronze, Silver y Gold. Indica qué servicio de Azure usarías en cada paso y justifica si optas por Fabric, Databricks u otro stack

- Ingesta de datos: Fabric Pipelines (Data Factory integrado). Es el servicio orquestador estrella de Azure y permite conectar de forma sencilla multitud de fuentes y programar los flujos de extracción de datos.
- Capa Bronze: OneLake (Fabric Lakehouse). Permite almacenar la ingesta exactamente como llega desde las fuentes originales, admitiendo todo tipo de formatos.
- Capa Silver: Fabric Spark Notebooks. Para transformar, limpiar datos y aplicar esquemas, Spark es el motor de procesamiento más potente y es el estándar. En esta etapa, Spark convierte los datos crudos y los guarda en formato Parquet en OneLake, preparándolos para futuras consultas.
- Capa Gold: Fabric Data Warehouse. Una vez que los datos están limpios en la capa Silver, el Data Warehouse es el servicio ideal para estructurarlos en modelos dimensionales (fact y dim) y realizar las

agregaciones necesarias.

- **Capa de consumo:** Power BI. Es una de las ventajas de fabric, al usar Direct Lake permite que Power BI consulte los datos (Delta Parquet) directamente, a una alta velocidad, eliminando la necesidad de importar, copiar o mover los datos a otro sitio.
- **Gobernanza:** Azure Purview y Entra ID. Indispensable para gobernar toda la plataforma. Gestiona quién tiene acceso a qué, supervisa el linaje de los datos y asegura el cumplimiento normativo en todas las capas. Como se puede observar, en casi todos los apartados se usa Fabric ya que está pensada para ser usada de forma sencilla (comparado con el resto de opciones) y ofrece ciertas ventajas. Todo esto, a un coste mucho más elevado que el resto de alternativas.



3. Formatos. Indica el formato de almacenamiento de cada capa y por qué.

- **Bronze:** Delta Lake (para fuentes de datos estructuradas/semiestructuradas) y BLOB/Archivos originales (PDF en su formato nativo). Porque mantienen los ficheros como en el origen, admitiendo la ingesta sin modificar tipos de datos ni estructuras.
- **Silver:** Delta Lake (Parquet + Transaction Log). Porque ofrece una compresión eficiente, capacidades de actualización/borrado (**UPDATE/DELETE**), evolución de esquemas y transacciones ACID para garantizar datos limpios, sin duplicar y unificados.
- **Gold:** Delta Lake / Parquet. Permite la conexión mediante **Direct Lake** desde Power BI, proporcionando el rendimiento de la memoria RAM (In-Memory) directamente sobre el Data Lake sin necesidad de duplicar ni importar los datos.

4. Modelo Gold. Diseña el esquema en estrella de ventas: tabla de hechos, granularidad, medidas y al menos cuatro dimensiones.

Granularidad: Línea de ticket de caja (cada producto individual dentro de una compra física u online). Esta es la base recomendada porque permite el máximo nivel de detalle.

Tabla de hechos (Fact_Ventas): Claves Foráneas (FK): id_fecha, id_tienda, id_producto, id_socio, id_promocion. Medidas (Métricas numéricas): cantidad_vendida, importe_venta (extraído de los tickets), descuento_aplicado, y margen.

Tablas dim:

1. Dim_Producto: id_producto, nombre_producto, familia.
2. Dim_Tienda: id_tienda, ciudad, superficie_m2, formato.
3. Dim_Socio: id_socio, nombre, y atributos extraídos de la app como preferencias (ej. ecológico, sin gluten) y consentimiento_marketing.
4. Dim_Fecha: id_fecha, día, mes, año, trimestre, estación.
5. Dim_Promocion: id_promocion, codigo_cupon (ej. FRUTA10), tipo_descuento.

5. Roles. Asigna cada paso de la arquitectura a uno de los siete roles vistos, incluyendo arquitecto de datos, analytics engineer y científico de datos.

1. Definición de Arquitectura y Topología: Arquitecto de Datos (Data Architect).
2. Configuración de BBDD Operativas y Backups: Administrador de Bases de Datos (DBA).
3. Desarrollo de Pipelines Ingesta (Bronze) y Limpieza (Silver): Ingeniero de Datos (Data Engineer).
4. Modelado Dimensional (Gold), Definición Semántica de Métricas y dbt: Analytics Engineer.
5. Desarrollo del Modelo Predictivo de Previsión de Demanda: Científico de Datos (Data Scientist).
6. Desarrollo del Asistente RAG / LLM en Azure AI Foundry: Ingeniero de IA (AI Engineer).
7. Construcción del Cuadro de Mando en Power BI: Analista de Datos (Data Analyst).

6. Métricas. Como analytics engineer, redacta la definición oficial de "rotura de stock" y dos pruebas de calidad que aplicarías a la tabla Gold.

Rotura de Stock: Situación operativa en la que el stock físico en tienda es igual a 0 unidades durante el horario de apertura al público, o cuando la demanda no atendida por la falta de stock genera una cancelación de pedidos en las ventas online.

1. Prueba de Integridad Referencial (Unicidad y No Nulos):
 - `ASSERT_NOT_NULL`: Ningún campo clave en `Fact_Ventas` (`ID_Fecha`, `ID_Tienda`, `ID_Producto`) puede contener valores nulos.
2. Prueba de Consistencia de Negocio (Reconciliation Test):
 - `ASSERT: Importe_Venta_Neto >= 0 AND Margen_Bruto <= Importe_Venta_Neto`. Falla la prueba si existen ventas netas negativas no justificadas por devoluciones registradas explícitamente.

7. Ciencia de datos. Indica qué tablas y variables necesitaría el científico de datos para el modelo de previsión de demanda y cómo escribirías sus predicciones de vuelta en la plataforma.

- Tabla Histórico de Ventas (`Fact_Ventas`): Unidades vendidas por SKU, tienda y día.
- Tabla de Inventario e Incidencias: Registros diarios de merma y roturas de stock.
- Tabla de Variables Externas (`Dim_Meteorologia` / `Dim_Festivos`):
 - `Temperatura_Media`, `Precipitacion_mm`.
 - `Es_Festivo`, `Víspera_De_Festivo`.
 - `Precio_Promocional` (Descuentos vigentes).

Reescritura de predicciones en la plataforma:

1. El modelo entrenado (ej. XGBoost / LightGBM en PySpark) ejecuta la inferencia por lotes diariamente.
2. Las predicciones se guardan en la capa Gold en una tabla Delta llamada `Gold_Prevision_Demanda` (`ID_Producto`, `ID_Tienda`, `Fecha_Futura`, `Unidades_Estimadas`).
3. El ERP de Compras lee directamente esa tabla Delta mediante un conector o vista SQL para sugerir automáticamente los pedidos de reposición a los proveedores.

8. Gobierno. Los datos de socios incluyen nombre, teléfono y correo. Explica qué harías en cada capa y qué papel juega Purview.

- Bronze: Almacena los datos de socios tal como llegan. Restricción estricta de acceso (solo rol de ingesta).

- Silver: Se aplican técnicas de enmascaramiento y hashado (SHA-256) sobre **Telefono** y **Correo**.
- Gold: Se eliminan completamente las columnas **Nombre**, **Telefono** y **Correo**. Solo se mantienen atributos agregados/demográficos (**Segmento**, **Provincia**).

Papel de Microsoft Purview:

- Descubrimiento y Clasificación: Escanea OneLake automáticamente e identifica los campos que contienen PII (ej. detección de patrones de teléfono y email).
- Linaje de Datos (Data Lineage): Registra el recorrido completo del dato desde Cosmos DB hasta el informe final de Power BI.
- Control de Acceso (Access Policies): Define políticas de masking unificadas a nivel de catálogo para evitar que usuarios no autorizados consulten información confidencial.

9. IA. Explica qué datos necesitaría el ingeniero de IA para construir el asistente en Foundry y qué requisitos de calidad le exigirías como ingeniero de datos.

1. Estructurados / Transaccionales: Estado del pedido en tiempo real (Base de datos relacional / API de e-commerce: **ID_Pedido**, **Estado**, **Fecha_Estimada_Entrega**, **Direccion**).
2. No Estructurados: Preguntas frecuentes (FAQ), Políticas de devolución, Tiempos de envío por zona geográfica en formato PDF/Markdown.

Requisitos de Calidad Exigidos al Ingeniero de IA:

- Latencia MÁXIMA: La respuesta del bot a la API de estado del pedido no debe superar los X segundos.
- Latencia de Actualización de Datos: Acceso a los datos de tracking con una latencia de sincronización mínima desde el sistema origen.
- Prevención de Alucinaciones: La IA debe limitarse a responder utilizando únicamente el contexto de la orden y la política definida; si el pedido no existe o el dato no está disponible, debe derivar a un agente humano en lugar de estimar o inventar la respuesta.

Sección 12: Repaso de conceptos

1. Un fichero donde cada evento puede tener campos distintos y anidados es un ejemplo de dato:

a) Estructurado **b) Semiestructurado** c) No estructurado d) Binario

2. ¿Qué formato almacena juntos los valores de cada columna y es el estándar de facto de los lakehouses?

a) Avro b) CSV **c) Parquet** d) XML

3. ¿Qué aporta Delta Lake sobre Parquet?

a) Legibilidad humana **b) Un registro de transacciones con ACID y versionado** c) Almacenamiento orientado a filas d) Soporte exclusivo para imágenes

4. Si una transacción crea un pedido pero falla la reserva de stock y se deshace todo, se está garantizando la:

a) Durabilidad **b) Atomicidad** c) Consistencia d) Disponibilidad

5. En el patrón ELT, las transformaciones se realizan:

a) Antes de extraer b) En un servidor intermedio **c) En el sistema de destino** d) En la aplicación de origen

6. ¿Qué capa de la arquitectura medallón contiene datos limpios, deduplicados y con tipos estandarizados?

a) Bronze **b) Silver** c) Gold d) Platinum

7. ¿Qué rol es el responsable de monitorizar que los pipelines de carga se ejecutan correctamente?

a) DBA b) Analista de datos **c) Ingeniero de datos** d) Ingeniero de IA

8. ¿Qué característica de Azure Storage permite usarlo como data lake?

a) File shares b) Tables **c) Espacio de nombres jerárquico sobre Blob** d) Colas

9. ¿Cuál es la opción recomendada de orquestación cuando todo el trabajo de datos se realiza dentro de Microsoft Fabric?

a) Azure Data Factory **b) Fabric Data Factory** c) Azure Stream Analytics d) Azure Data Explorer

10. ¿Qué servicio usarías para trazar el linaje de un dato desde el TPV hasta un informe de Power BI?

a) Microsoft Foundry b) Azure Cosmos DB **c) Microsoft Purview** d) Azure Databricks

11. Microsoft Fabric se ofrece como:

a) IaaS b) PaaS **c) SaaS** d) On-premises

12. Una empresa necesita detectar en tiempo real cámaras frigoríficas que superan un umbral de temperatura. ¿Qué servicio encaja mejor?

a) Power BI **b) Azure Stream Analytics** c) Azure SQL Managed Instance d) Microsoft Purview

13. ¿Qué rol es responsable de que la métrica "venta neta" tenga una única definición oficial, probada y documentada?

a) DBA **b) Analytics engineer** c) Ingeniero de IA d) Científico de datos

14. ¿Qué rol construiría un modelo para predecir qué clientes dejarán de comprar en los próximos meses?

a) Analista de datos b) Arquitecto de datos **c) Científico de datos** d) DBA

15. ¿Qué rol decide si la plataforma de la empresa se organiza por dominios y qué servicios se usan en cada capa?

a) Arquitecto de datos b) Analytics engineer c) Analista de datos d) Ingeniero de IA